

分类号: \_\_\_\_\_

单位代码: \_\_\_\_\_

学 号: \_\_\_\_\_

# 浙江大学

## 博士学位论文开题报告



中文论文题目: 基于行人重识别的跨摄像头  
多目标跟踪方法研究

英文论文题目: Study on multi-target multi-camera tracking  
based on person re-identification

姓名: 罗浩

导师: 姜伟

专业: 控制科学与工程

学号: 11532034

学院: 控制学院

报告日期 2017年11月

## 摘 要

**关键词：**行人重识别，跨摄像头多目标跟踪，深度学习，卷积神经网络

# 目 次

摘要 .....	I
目次	
1 研究意义与背景 .....	1
2 研究现状与文献综述 .....	2
2.1 行人重识别 .....	2
2.1.1 相关数据集 .....	2
2.1.2 准确度评估准则 .....	4
2.1.3 基于表征学习的方法 .....	6
2.1.4 基于度量学习的方法 .....	7
2.1.5 基于局部特征的方法 .....	10
2.1.6 基于视频序列的方法 .....	13
2.2 跨摄像头多目标跟踪 .....	15
2.2.1 相关数据集 .....	15
3 研究内容与技术路线 .....	16
4 现有成果与研究计划 .....	17
4.1 现有成果 .....	17
4.1.1 边界样本挖掘损失 .....	17
4.1.2 最短路径距离 .....	20
4.1.3 基于度量学习的互学习方法 .....	23
4.1.4 行人重识别的人类准确度评估 .....	26
4.1.5 与现有方法结果对比 .....	27
4.2 成果作品 .....	28
4.3 研究现状 .....	28
参考文献 .....	29

## 1 研究意义与背景

## 2 研究现状与文献综述

本章节主要介绍本课题相关的研究现状，包括行人重识别(Person re-identification, person ReID)和跨摄像头多目标跟踪(Multi-target multi-camera tracking, MTMC tracking)两个部分。在本章节将会分别介绍这两个子课题相关的数据集和现有算法。其中行人重识别着重介绍近几年深度卷积神经网络相关的方法，而跨摄像头多目标跟踪将会着重介绍基于行人重识别的方法。

### 2.1 行人重识别

行人重识别也称行人再识别，是利用计算机视觉技术判断图像或者视频序列中是否存在特定行人的技术。广泛被认为是一个图像检索的子问题。给定一个监控行人图像，检索跨设备下的该行人图像。旨在弥补目前固定的摄像头的视觉局限，并可与行人检测/行人跟踪技术相结合，可广泛应用于智能视频监控、智能安保等领域。

而对于跨摄像头多目标跟踪问题，当一个行人目标在其中一个摄像头视野中消失后，要把该行人在其他摄像头中再次识别出来，这就是典型的行人重识别问题。也就是说，行人重识别技术是跨摄像头多目标跟踪的基础。因此，在本小节将会先介绍现有的行人重识别相关的数据集、准确度评估准则和一些现有的主流方法。

#### 2.1.1 相关数据集

行人重识别相关的数据集总共有十几个，在早年深度学习还未出现的时候，那时的数据集图片数量还比较少。随着深度学习的诞生，行人重识别问题对数据量的要求大大增加，本小节将介绍几个适用深度学习的大规模行人识别数据集。

- Market1501

Market1501<sup>[1]</sup>是在清华大学校园中采集，图像来自6个不同的摄像头，其中有一个摄像头为低像素。同时该数据集提供训练集和测试集。训练集包含12,936张图像，测试

集包含19,732张图像。图像由检测器自动检测并切割，包含一些检测误差（接近实际使用情况）。训练数据中一共有751人，测试集中有750人。所以在训练集中，平均每类（每个人）有17.2张训练数据。

- **MARS**

**MARS** (Motion Analysis and Re-identification Set)<sup>[2]</sup>数据集是Market1501的扩展。该数据集的图像由检测器自动切割，包含了行人图像的整个跟踪序列(tracklet)。MARS总共提供1,267个行人的20,478个图像序列，和Market1501一样来自同样的6个摄像头。和其他单帧图像数据集不一样的地方是，MARS是提供序列信息的大规模行人重识别数据集。

- **CUHK03**

**CUHK03**<sup>[3]</sup>在香港中文大学采集，图像来自2个不同的摄像头。该数据集提供机器自动检测和手动检测两个数据集。其中检测数据集包含一些检测误差，更接近实际情况。数据集总共包括1,467个行人的14,097张图片，平均每个人有9.6张训练数据。

- **CUHK-SYSU**

**CUHK-SYSU**<sup>[4]</sup>是香港中文大学和中山大学一起收集的数据集。该数据集的特点是提供整个完整的图片，而不像其他大部分数据集一样只提供自动或者手动提取边框(bounding box)的行人图片。该数据集总共包括18,184张完整图片，内含8,432个行人的99,809张行人图片。其中训练集有11,206张完整图片，包含5,532个行人。测试集有6,978张完整图片，包含2,900个行人。

- **DukeMTMC-reID**

**DukeMTMC-reID**<sup>[5]</sup>在杜克大学内采集，图像来自8个不同摄像头，行人图像的边框由人工标注完成。该数据集提供训练集和测试集。训练集包含16,522张图像，测试集包含17,661张图像。训练数据中一共有702人，平均每个人有23.5张训练数据。该数据集是目前最大的行人重识别数据集，并且提供了行人属性（性别/长短袖/是否背包等）的标注。

- **VIPeR**

**VIPeR**<sup>[6]</sup>数据集是早期的一个小型行人重识别数据集，图像来自2个摄像头。该数据集总共包含632个行人的1,264，每个行人有两张不同摄像头拍摄的图片。数据集随

机分为相等的两部分，一部分作为训练集，一部分作为测试集。由于采集时间较早，该数据集的图像分辨率非常低，所以识别难度较大。

- PRID2011

PRID2011<sup>[7]</sup>是2011年提出的一个数据集，图像来自于2个不同的摄像头。该数据集总共包含934个行人的24,541张行人图片，所以的检测框都是人工手动提取。图像大小的分辨率统一为128×64的分辨率。

以上是目前行人重识别研究中主要运用的数据集。由于行人重识别图片采自于不同摄像头，所以会出现光照、行人姿态、拍摄角度、遮挡、图像模糊等问题，造成同一行人的图片在不同摄像头中表现差异很大。如图2-1所示，上一排与下一排为同一个行人在两个不同摄像头拍摄的图片。可以看出，第一列存在遮挡现象，第二列至第四列存在拍摄角度、姿态等的巨大差异，第五列由于拍摄距离不同造成行人占图像比例大小差异很大，而最后一列是典型的摄像头分辨率不同而造成的图像差异。正式因为各种因素造成的图像差异，使得行人重识别很难通过手动提取特征就达到很好的识别效果，需要通过一定手段来学习到非常鲁棒的图像特征。

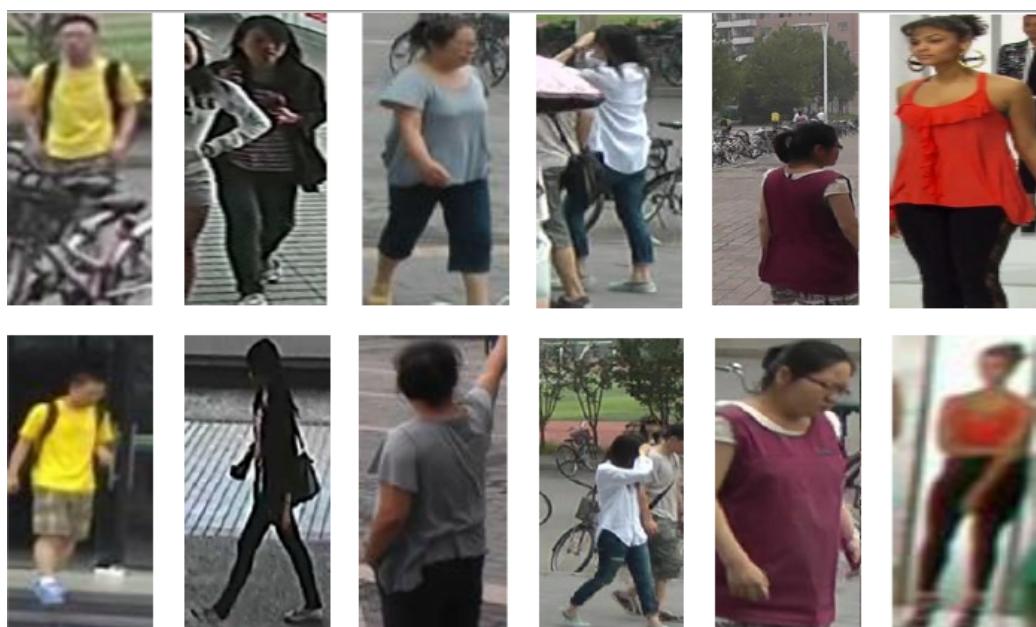


图 2-1 行人重识别数据集图片示例

### 2.1.2 准确度评估准则

为了评估行人重识别算法的优劣，需要统一一些评价准则。在学术论文中，通常大家默认选择累计匹配(Cumulative Match Characteristics, CMC)曲线和平均准确度(Mean Average

Precision, mAP)来作为评价准则。CMC和mAP是检索问题中常用的评价准则，在介绍它们之前，我们先介绍一些要用到常用术语。

- **query:** 指测试集中的待检索库,包含图片的数目为 $N_q$ 。
- **gallery:** 指测试集中的搜索库。
- **probe:** 指query中的某张待检索的图片，测试时需要将gallery中和probe为同一行人的图片全部检索出来。

### (1) CMC曲线

CMC曲线主要用于计算rank-k的击中概率，在行人重识别、人脸识别领域使用较多。针对query集中的一张带检索的probe图片，返回gallery的一系列排好序的结果，排序按照相似度排序。越靠前的结果表示和probe图片越相似，在行人重识别领域也等同于和probe是同一个人的概率越高。在测试阶段，需要排除gallery集中和probe处于同一摄像头的图片，防止其参与检索排序。我们设 $index_{probe}$ 表示和gallery和probe为相同行人的最靠前的排序结果。最后rank-k准确度 $A(rank-k)$ 可以表示为：

$$A(rank-k) = \frac{\sum_{probe \in query} f_{CMC}(index_{probe}, k)}{N_q} \quad (2-1)$$

其中：

$$f_{CMC}(index_{probe}, k) = \begin{cases} 0 & index_{probe} > k \\ 1 & index_{probe} \leq k \end{cases} \quad (2-2)$$

在实际使用中，为了减少计算量，通常我们比较关心rank-1,rank-5,rank-10,rank-20等准确度。

### (2) mAP

mAP是另外一种重要的评价指标。CMC曲线通常只关心检索库中最靠前的正样本排序，而mAP由gallery中所有正样本的排序结果决定，所以通常能够更加鲁邦地反映模型的性能。计算mAP需要以下三步：

- (1) Precision: 对于query中的某一张probe图片，返回了gallery的一系列排序结果，考虑前 $n$ 个查询结果， $P(n)=$ 前 $n$ 个结果中与probe图片是相同行人的数目/ $n$ ；
- (2) Average Precision: 对于query的第 $K$ 个probe图片，记录排序结果中所有M个正样本排序结果的集合 $\{i_1, i_2, \dots, i_M\}$ ，计算它们的平均Precision，即 $AP_K = \sum P(i)/M$ ，其中 $i \in \{i_1, i_2, \dots, i_M\}$ ；

(3) Mean Average Precision (mAP): 所有 $N_q$ 张probe图片的Average Precision 的平均值, 即 $mAP = \sum_K AP_K/N$ 。

### 2.1.3 基于表征学习的方法

基于表征学习(Representation learning)的方法是一类非常常用的行人重识别方法<sup>[8-11]</sup>。这主要得益于深度学习, 尤其是卷积神经网络(Convolutional neural network, CNN)<sup>[12]</sup>的快速发展。由于CNN可以自动从原始的图像数据中根据任务需求自动提取出表征特征(Representation), 所以有些研究者把行人重识别问题看做分类(Classification/Identification)问题或者验证(Verification)问题。分类问题是利用行人的ID或者属性等作为训练标签来训练模型。验证问题是输入一对(两张)行人图片, 让网络来学习这两张图片是否属于同一个行人。

论文<sup>[8]</sup>利用Classification/Identification loss和verification loss来训练网络, 其网络示意图如图2-2所示。网络输入为若干对行人图片, 包括分类子网络(Classification Subnet)和验证子网络(Verification Subnet)。分类子网络对图片进行ID预测, 根据预测的ID来计算分类误差损失。验证子网络融合两张图片的特征, 判断这两张图片是否属于同一个行人, 该子网络实质上等于一个二分类网络。经过足够数据的训练, 再次输入一张测试图片, 网络将自动提取出一个特征, 这个特征用于行人重识别任务。

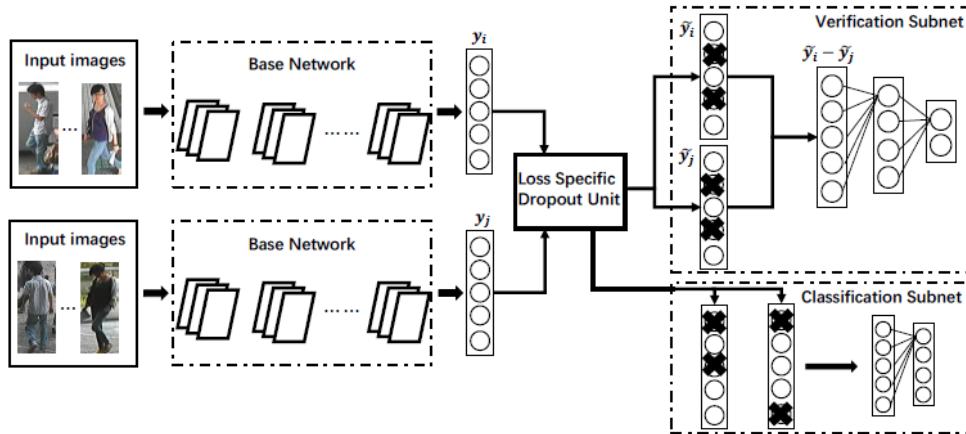


Figure 1. The proposed deep Re-ID network architecture.

图 2-2 结合分类损失和验证损失训练ReID网络示意图

论文<sup>[9-11]</sup>认为光靠行人的ID信息不足以学习出一个泛化能力足够强的模型。在这些工作中, 它们额外标注了行人图片的属性特征, 例如性别、头发、衣着等属性。通过引入行人属性标签, 模型不但要准确地预测出行人ID, 还要预测出各项正确的行人属性, 这大大增加了模型的泛化能力, 多数论文也显示这种方法是有效的。图2-3是其中一个示例, 从

图中可以看出，网络输出的特征不仅用于预测行人的ID信息，还用于预测各项行人属性。通过结合ID损失和属性损失能够提高网络的泛化能力。

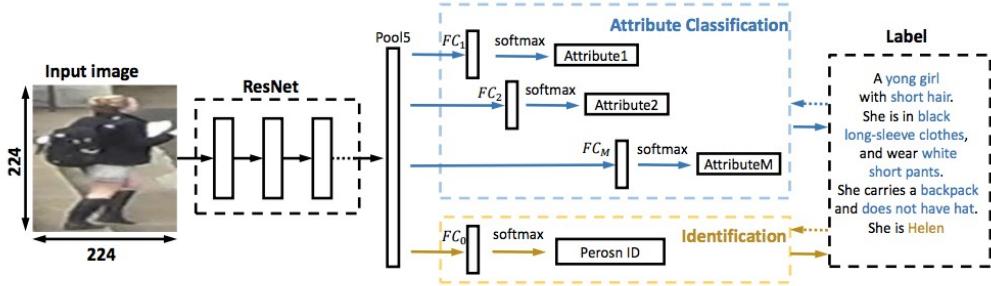


Figure 2. An overview of the APR network. During training, it predicts  $M$  attribute labels and an ID label. The weighted sum of the individual losses is back propagated. During testing, we extract the Pool5 (ResNet-50) or FC7 (CaffeNet) descriptors for retrieval.

图 2-3 结合行人ID标注和行人属性训练ReID网络示例

#### 2.1.4 基于度量学习的方法

度量学习(Metric learning)是广泛用于图像检索利的一种方法。不同于表征学习，度量学习旨在通过网络学习出两张图片的相似度。在行人重识别问题上，具体为同一行人的不同图片相似度大于不同行人的不同图片。最后网络的损失函数使得相同行人图片(正样本对)的距离尽可能小，不同行人图片(负样本对)的距离尽可能大。常用的度量学习损失方法有对比损失(Contrastive loss)<sup>[13]</sup>、三元组损失(Triplet loss)<sup>[14-16]</sup>、四元组损失(Quadruplet loss)<sup>[17]</sup>。首先，假如有两张输入图片 $I_1$ 和 $I_2$ ，通过网络的前馈我们可以得到它们归一化后的特征向量 $f_{I_1}$ 和 $f_{I_2}$ 。我们定义这两张图片特征向量的欧式距离为：

$$d_{I_1, I_2} = \|f_{I_1} - f_{I_2}\|_2 \quad (2-3)$$

##### (1) 对比损失(Contrastive loss)

对比损失用于训练孪生网络(Siamese network)，其结构图如图2-4所示。孪生网络的输入为一对(两张)图片 $I_a$ 和 $I_b$ ，这两张图片可以为同一行人，也可以为不同行人。每一对训练图片都有一个标签 $y$ ，其中 $y = 1$ 表示两张图片属于同一个行人(正样本对)，反之 $y = 0$ 表示它们属于不同行人(负样本对)。之后，对比损失函数写作：

$$L_c = y d_{I_a, I_b}^2 + (1 - y)(\alpha - d_{I_a, I_b})_+^2 \quad (2-4)$$

其中 $(z)_+$ 表示 $\max(z, 0)$ ， $\alpha$ 是根据实际需求设计的阈值参数。为了最小化损失函数，当网络输入一对正样本对， $d(I_a, I_b)$ 会逐渐变小，即相同ID的行人图片会逐渐在特征空间形成聚类。反之，当网络输入一对负样本对时， $d(I_a, I_b)$ 会逐渐变大直到超过设定的 $\alpha$ 。

通过最小化 $L_c$ ，最后可以使得正样本对之间的距离逐渐变下，负样本对之间的距离逐渐变大，从而满足行人重识别任务的需要。

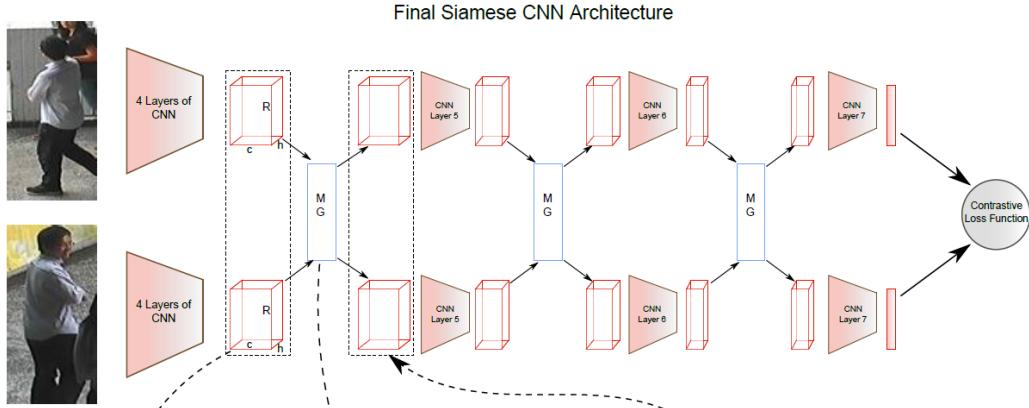


图 2-4 孪生网络结构示意图

## (2) 三元组损失(Triplet loss)

三元组损失是一种被广泛应用的度量学习损失，之后的大量度量学习方法也是基于三元组损失演变而来。顾名思义，三元组损失需要三张输入图片。和对比损失不同，一个输入的三元组 (Triplet) 包括一对正样本对和一对负样本对。三张图片分别命名为固定图片(Anchor)  $a$ ，正样本图片(Positive)  $p$ 和负样本图片(Negative)  $n$ 。图片 $a$ 和图片 $p$ 为一对正样本对，图片 $a$ 和图片 $n$ 为一对负样本对。则三元组损失表示为：

$$L_t = (d_{a,p} - d_{a,n} + \alpha)_+ \quad (2-5)$$

如图2-5所示，三元组可以拉近正样本对之间的距离，推开负样本对之间的距离，最后使得相同ID的行人图片在特征空间里形成聚类，达到行人重识别的目的。

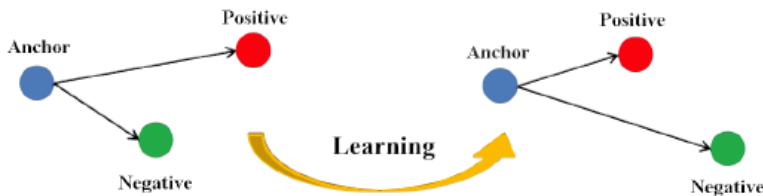


Figure 4. Triplet loss.

图 2-5 三元组损失<sup>[18]</sup>

论文<sup>[16]</sup>认为公式(4-1)只考虑正负样本对之间的相对距离，而并没有考虑正样本对之间的绝对距离，为此提出改进三元组损失(Improved triplet loss)：

$$L_{it} = d_{a,p} + (d_{a,p} - d_{a,n} + \alpha)_+ \quad (2-6)$$

公式(2-6)添加 $d_{a,p}$ 项，保证网络不仅能够在特征空间把正负样本推开，也能保证正样本对之间的距离很近。

### (3) 四元组损失(Quadruplet loss)

四元组损失是三元组损失的另一个改进版本。顾名思义，四元组(Quadruplet)需要四张输入图片，和三元组不同的是多了一张负样本图片。即四张图片为固定图片(Anchor)  $a$ ，正样本图片(Positive)  $p$ ，负样本图片1(Negative1)  $n_1$  和负样本图片2(Negative2)  $n_2$ 。其中  $n_1$  和  $n_2$  是两张不同行人ID的图片，其结构如图2-6所示。则，四元组损失表示为：

$$L_q = (d_{a,p} - d_{a,n_1} + \alpha)_+ + (d_{a,p} - d_{n_1,n_2} + \beta)_+ \quad (2-7)$$

其中 $\alpha$ 和 $\beta$ 是手动设置的正常数，通常设置 $\beta$ 小于 $\alpha$ ，前一项称为强推动，后一项称为弱推动。相比于三元组损失只考虑正负样本间的相对距离，四元组添加的第二项不共享ID，所以考虑的是正负样本间的绝对距离。因此，四元组损失通常能让模型学习到更好的表征。

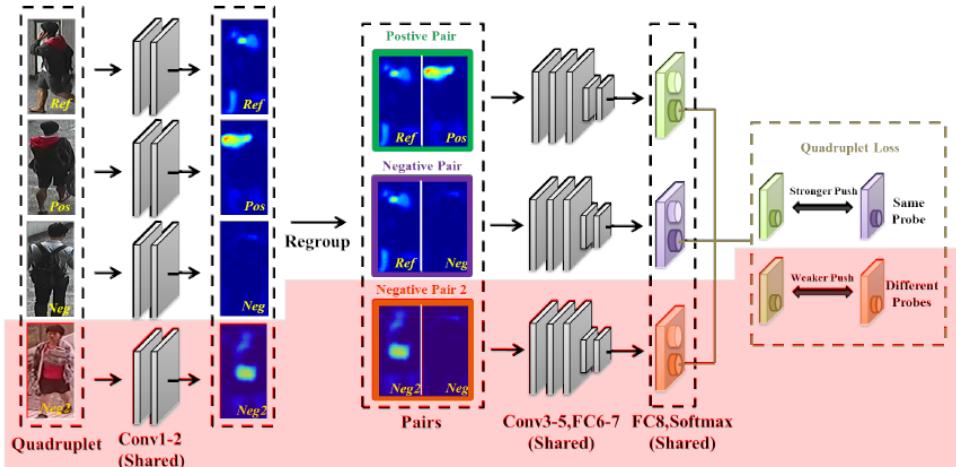


Figure 3. The framework of the proposed quadruplet deep network. The red shadow region indicates elements of the new constraint.

图 2-6 四元组损失网络结构图

### (4) 难样本采样三元组损失(Triplet loss with hard sample mining)

难样采样三元组损失（本文之后用TriHard损失表示）是三元组损失的改进版。传统的三元组随机从训练数据中抽样三张图片，这样的做法虽然比较简单，但是抽样出来的大部分都是简单易区分的样本对。如果大量训练的样本对都是简单的样本对，那么这是不利于网络学习到更好的表征。大量论文发现用更难的样本去训练网络能够提高网络的泛化能力，而采样难样本对的方法很多。论文<sup>[19]</sup>提出了一种基于训练批量(Batch)的在线难样本采样方法——TriHard损失。

**TriHard**损失的核心思想是：对于每一个训练batch，随机挑选 $P$ 个ID的行人，每个行人随机挑选 $K$ 张不同的图片，即一个batch含有 $P \times K$ 张图片。之后对于batch中的每一张图片 $a$ ，我们可以挑选一个最难的正样本和一个最难的负样本和 $a$ 组成一个三元组。

首先我们定义和 $a$ 为相同ID的图片集为 $A$ ，剩下不同ID的图片图片集为 $B$ ，则**TriHard**损失表示为：

$$L_{th} = \frac{1}{P \times K} \sum_{a \in batch} (\max_{p \in A} d_{a,p} - \min_{n \in B} d_{a,n} + \alpha)_+ \quad (2-8)$$

其中 $\alpha$ 是人为设定的阈值参数。**TriHard**损失会计算 $a$ 和batch中的每一张图片在特征空间的欧式距离，然后选出与 $a$ 距离最远（最不像）的正样本 $p$ 和距离最近（最像）的负样本 $n$ 来计算三元组损失。通常**TriHard**损失效果比传统的三元组损失要好。

### 2.1.5 基于局部特征的方法

从网络的训练损失函数上进行分类可以分成表征学习和度量学习，相关方法前文已经介绍。另一个角度，从抽取图像特征进行分类，行人重识别的方法可以分为基于全局特征(Global feature) 和基于局部特征(Local feature)的方法。全局特征是指让网络对整幅图像提取一个特征，这个特征不考虑一些局部信息。而局部特征是指让手动或者自动地让网络去关注关键的局部区域，然后提取这些区域的局部特征。常用的提取局部特征的思路主要有图像切块、利用骨架关键点定位以及姿态矫正等等。

图片切块是一种很常见的提取局部特征方式<sup>[20,21]</sup>。如图2-7所示，图片被垂直等分为若干份，因为垂直切割更符合我们对人体识别的直观感受，所以行人重识别领域很少用到水平切割。之后，被分割好的若干块图像块按照顺序送到一个长短时记忆网络(Long short term memory network, LSTM)，最后的特征融合了所有图像块的局部特征。但是这种缺点在于对图像对齐的要求比较高，如果两幅图像没有上下对齐，那么很可能出现头和上身对比的现象，反而使得模型判断错误。

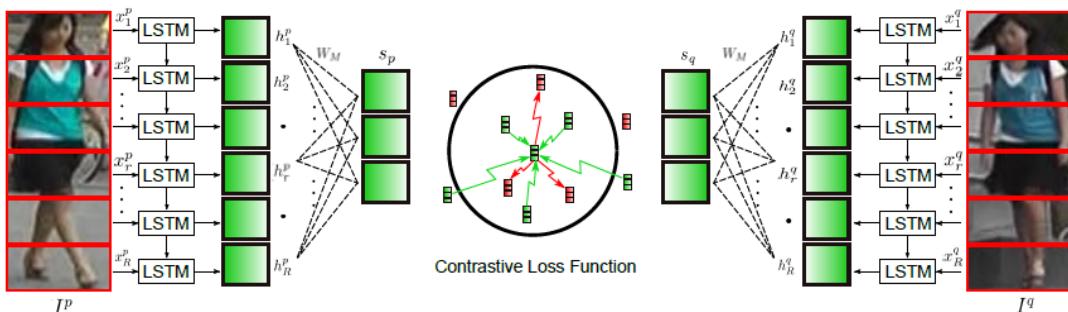


图 2-7 利用图片切块提取局部特征示例

为了解决图像不对齐情况下手动图像切片失效的问题，一些论文利用一些先验知识先将行人进行对齐，这些先验知识主要是预训练的人体姿态(Pose)和骨架关键点(Skeleton)模型。论文<sup>[22]</sup>先用姿态估计的模型估计出行人的关键点，然后用仿射变换使得相同的关键点对齐。如图2-8所示，一个行人通常被分为14个关键点，这14个关键点把人体结果分为若干个区域。为了提取不同尺度上的局部特征，作者设定了三个不同的PoseBox组合。之后这三个PoseBox矫正后的图片和原始未矫正的图片一起送到网络里去提取特征，这个特征包含了全局信息和局部信息。特别提出，如果这个仿射变换可以在进入网络之前的预处理中进行，也可以在输入到网络后进行。如果是后者的话需要对仿射变换做一个改进，因为传统的放射变化是不可导的。为了使得网络可以训练，需要引入可导的近似放射变化，在本文中不赘述相关知识。

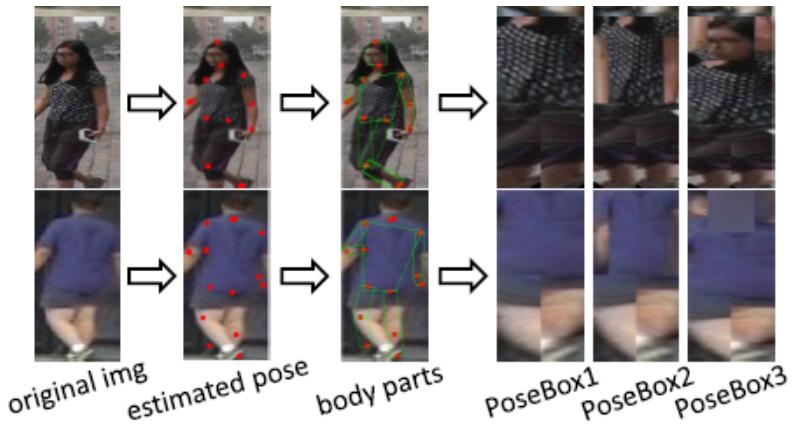


图 2-8 姿态对齐示意图

CVPR2017的工作Spindle Net<sup>[23]</sup>也利用了14个人体关键点来提取局部特征。和论文<sup>[22]</sup>不同的是，Spindle Net并没有用仿射变换来对齐局部图像区域，而是直接利用这些关键点来抠出感兴趣区域(Region of interest, ROI)。Spindle Net网络如图2-9所示，首先通过骨架关键点提取的网络提取14个人体关键点，之后利用这些关键点提取7个人体结构ROI。网络中所有提取特征的CNN（橙色表示）参数都是共享的，这个CNN分成了线性的三个子网络FEN-C1、FEN-C2、FEN-C3。对于输入的一张行人图片，有一个预训练好的骨架关键点提取CNN（蓝色表示）来获得14个人体关键点，从而得到7个ROI区域，其中包括三个大区域（头、上身、下身）和四个四肢小区域。这7个ROI区域和原始图片进入同一个CNN网络提取特征。原始图片经过完整的CNN得到一个全局特征。三个大区域经过FEN-C2和FEN-C3子网络得到三个局部特征。四个四肢区域经过FEN-C3子网络得到四个局部特征。之后这8个特征按照图示的方式在不同的尺度进行联结，最终得到一个融合全局特征和多个尺度局部特征的行人重识别特征。

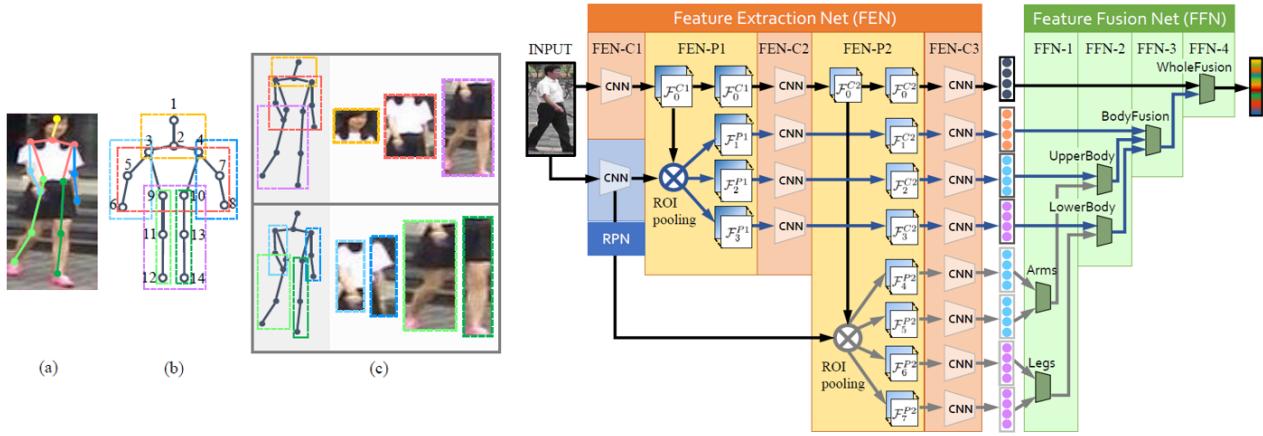


图 2-9 Spindle Net 结构示意图

论文<sup>[24]</sup>提出了一种全局-局部对齐特征描述子(Global-Local-Alignment Descriptor, GLAD), 来解决行人姿态变化的问题。与Spindle Net类似, GLAD利用提取的人体关键点把图片分为头部、上身和下身三个部分。之后将整图和三个局部图片一起输入到一个参数共享CNN网络中, 最后提取的特征融合了全局和局部的特征。为了适应不同分辨率大小的图片输入, 网络利用全局平均池化(Global average pooling, GAP)来提取各自的特征。和Spindle Net略微不同的是四个输入图片各自计算对应的损失, 而不是融合为一个特征计算一个总的损失。

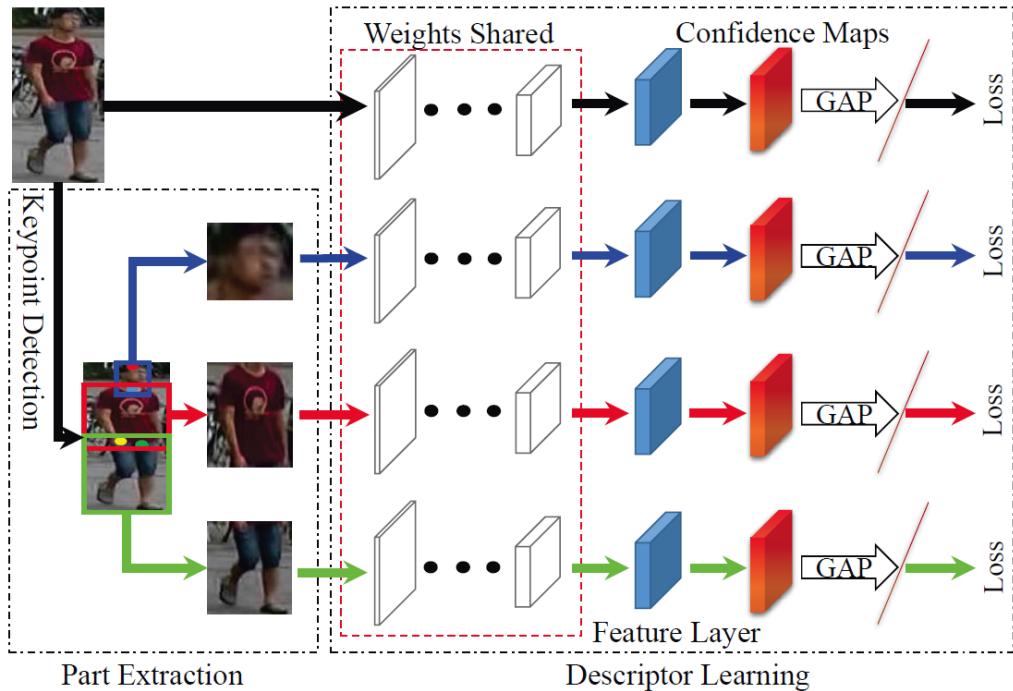


图 2-10 GLAD 结构示意图

### 2.1.6 基于视频序列的方法

以上介绍的方法都是基于单帧图像的方法，通常单帧图像的信息是有限的，因此有很多工作集中在利用视频序列来进行行人重识别方法的研究<sup>[25-31]</sup>。基于视频序列的方法最主要的不同点就是这类方法不仅考虑了图像的内容信息，还考虑了帧与帧之间的运动信息等。

基于单帧图像的方法主要思想是利用CNN来提取图像的空间特征，而基于视频序列的方法主要思想是利用CNN来提取空间特征的同时利用递归循环网络(Recurrent neural networks, RNN)来提取时序特征。图2-11是非常典型的思路，网络输入为图像序列。每张图像都经过一个共享的CNN提取出图像空间内容特征，之后这些特征向量被输入到一个RNN网络去提取最终的特征。最终的特征融合了单帧图像的内容特征和帧与帧之间的运动特征。而这个特征用于代替前面单帧方法的图像特征来训练网络。

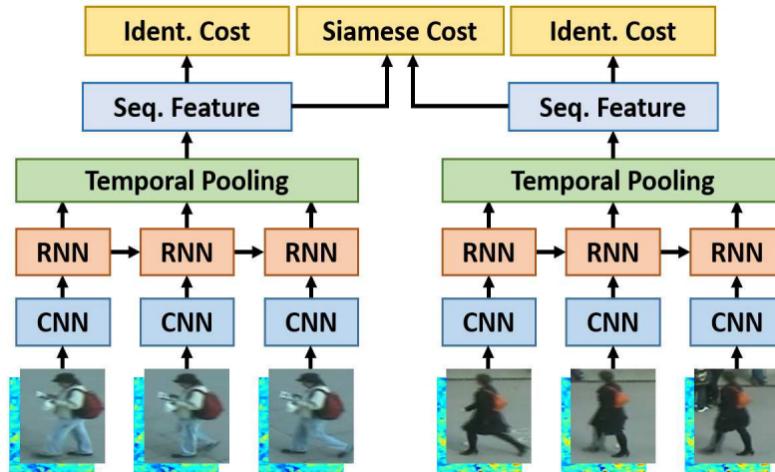


图 2-11 基于视频序列的行人重识别网络结构示意图

视频序列类的代表方法之一是累计运动背景网络(Accumulative motion context network, AMOC)<sup>[31]</sup>。AMOC输入的包括原始的图像序列和提取的光流序列。通常提取光流信息需要用到传统的光流提取算法，但是这些算法计算耗时，并且无法与深度学习网络兼容。为了能够得到一个自动提取光流的网络，作者首先训练了一个运动信息网络(Motion network, Moti Nets)。这个运动网络输入为原始的图像序列，标签为传统方法提取的光流序列。如图2-12所示，原始的图像序列显示在第一排，提取的光流序列显示在第二排。网络有三个光流预测的输出，分别为Pred1, Pred2, Pred3，这三个输出能够预测三个不同尺度的光流图。最后网络融合了三个尺度上的光流预测输出来得到最终光流图，预测的光流序列在第三排显示。通过最小化预测光流图和提取光流图的误差，网络能够提取出较准确的运动特征。

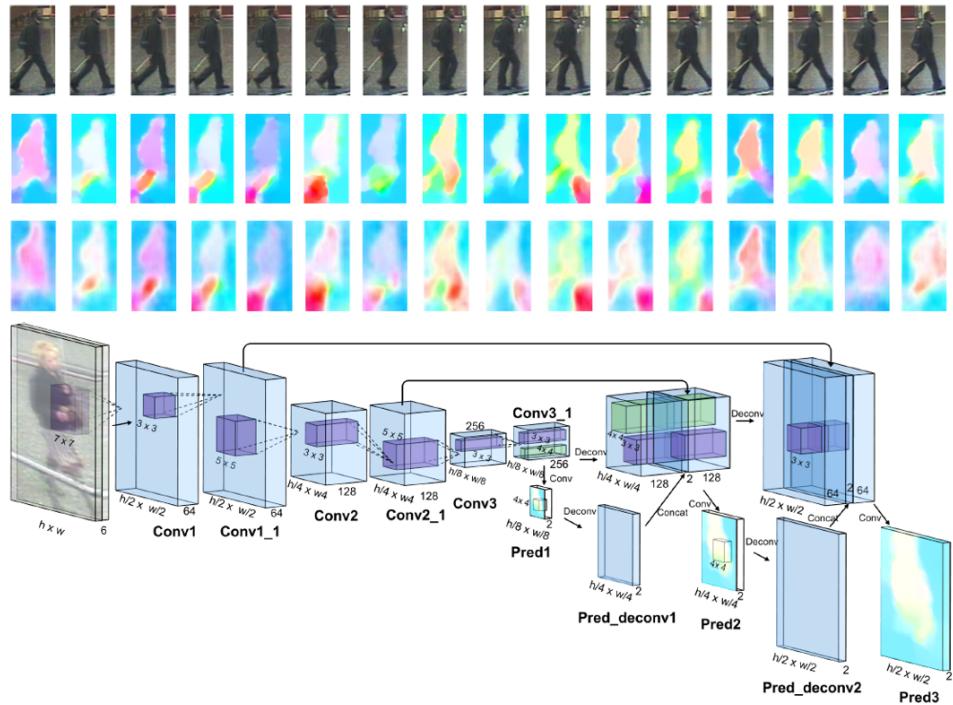


图 2-12 运动网络结构示意图

AMOC的核心思想在于网络除了要提取序列图像的特征，还要提取运动光流的运动特征，其网络结构图如图2-13所示。AMOC拥有空间信息网络(Spatial network, Spat Nets)和运动信息网络两个子网络。图像序列的每一帧图像都被输入到Spat Nets来提取图像的全局内容特征。而相邻的两帧将会送到Moti Nets来提取光流图特征。之后空间特征和光流特征融合后输入到一个RNN来提取时序特征。通过AMOC网络，每个图像序列都能被提取出一个融合了内容信息、运动信息的特征。网络采用了分类损失和对比损失来训练模型。融合了运动信息的序列图像特征能够提高行人重识别的准确度。

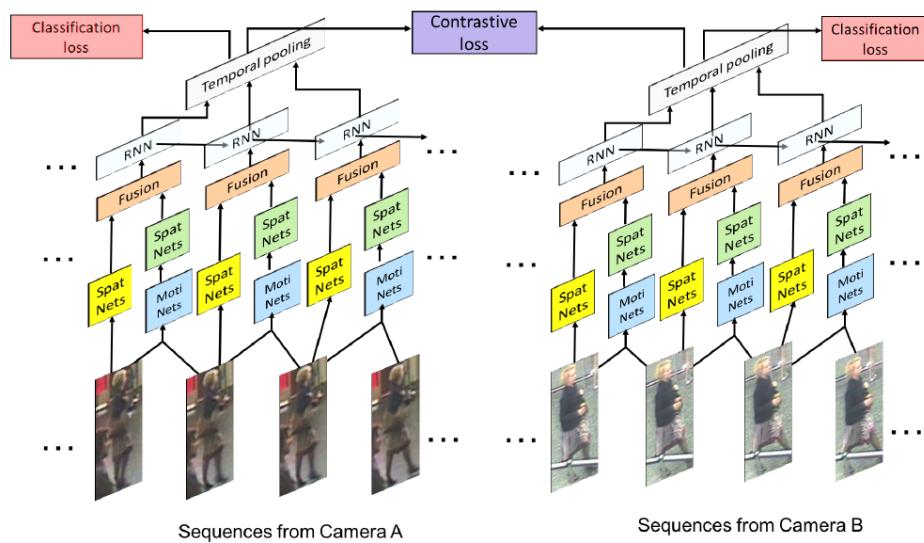


图 2-13 AMOC结构示意图

## 2.2 跨摄像头多目标跟踪

### 2.2.1 相关数据集

### 3 研究内容与技术路线

## 4 现有成果与研究计划

### 4.1 现有成果

本章节介绍了现在已经取得的一些科研成果，并且根据已有的成果初步制定了一下未来的研究计划。

#### 4.1.1 边界样本挖掘损失

边界样本挖掘损失(Margin sample mining loss, MSML)是一种引入难样本采样思想的度量学习方法。度量学习的目标是学习一个函数 $g(x) : \mathbb{R}^F \rightarrow \mathbb{R}^D$ ，使得 $\mathbb{R}^F$ 空间上语义相似度反映在 $\mathbb{R}^D$ 空间的距离上。通常我们需要定义一个距离度量函数 $D(x, y) : \mathbb{R}^D \times \mathbb{R}^D \rightarrow \mathbb{R}$ 来表示嵌入空间(Embedding space)的距离，而这个距离也用来重识别行人图片。

在国内外研究现状里面介绍的三元组损失、四元组损失和TriHard损失都是典型度量学习方法。给定一个三元组 $\{a, p, n\}$ ，三元组损失表示为：

$$L_t = (d_{a,p} - d_{a,n} + \alpha)_+ \quad (4-1)$$

三元组损失只考虑了正负样本对之间的相对距离。为了引入正负样本对之间的绝对距离，四元组损失加入一张负样本组成了四元组 $\{a, p, n_1, n_2\}$ ，而四元组损失也定义为：

$$L_q = (d_{a,p} - d_{a,n_1} + \alpha)_+ + (d_{a,p} - d_{n_1,n_2} + \beta)_+ \quad (4-2)$$

假如我们忽视参数 $\alpha$ 和 $\beta$ 的影响，我们可以用一种更加通用的形式表示四元组损失：

$$L_{q'} = (d_{a,p} - d_{m,n} + \alpha)_+ \quad (4-3)$$

其中 $m$ 和 $n$ 是一对负样本对， $m$ 和 $a$ 既可以是一对正样本对也可以是一对负样本对。但是直接使用(4-3)并不能取得很好的结果，因为随着数据量的上升，可能四元组组合数量急剧上升。绝大部分样本对都是比较简单的，这限制了模型的性能。为了解决这个问题，我们采用了TriHard损失<sup>[19]</sup>使用的难样本采样思想。TriHard损失是在一个batch里面计算三元组

损失。对于batch中的每一张图片 $a$ , 我们可以挑选一个最难的正样本和一个最难的负样本和 $a$ 组成一个三元组。我们定义和 $a$ 为相同ID的图片集为 $A$ , 剩下不同ID的图片图片集为 $B$ , 则TriHard损失表示为:

$$L_{th} = \frac{1}{P \times K} \sum_{a \in batch} (\max_{p \in A} d_{a,p} - \min_{n \in B} d_{a,n} + \alpha)_+ \quad (4-4)$$

而TriHard损失同样只考虑了正负样本对之间的相对距离, 而没有考虑它们之间的绝对距离。于是我们把这种难样本采样的思想引入到(4-3), 可以得到:

$$L_{msml} = (\max_{a,p} d_{a,p} - \min_{m,n} d_{m,n} + \alpha)_+ \quad (4-5)$$

其中 $a, p, m, n$ 均是batch中的图片,  $a, p$ 是batch中最不像的正样本对,  $m, n$ 是batch中最像的负样本对,  $a, m$ 皆可以是正样本对也可以是负样本对。概括而言TriHard损失是针对batch中的每一张图片都挑选了一个三元组, 而MSML损失只挑选出最难的一个正样本对和最难的一个负样本对计算损失。所以MSML是比TriHard更难的一种难样本采样, 此外 $\max_{a,p} d_{a,p}$ 可以看作是正样本对距离的上界,  $\min_{m,n} d_{m,n}$ 可以看作是负样本对的下界。MSML是为了把正负样本对的边界给推开, 因此命名为边界样本挖掘损失。MSML只用了两对样本对计算损失, 看上去浪费了很多训练数据。但是这两对样本对是根据整个batch的结果挑选出来了, 所以batch中的其他图片也间接影响了最终的损失。并且随着训练周期的增加, 几乎所有的数据都会参与损失的计算。总的概括, MSML是同时兼顾相对距离和绝对距离并引入了难样本采样思想的度量学习方法。

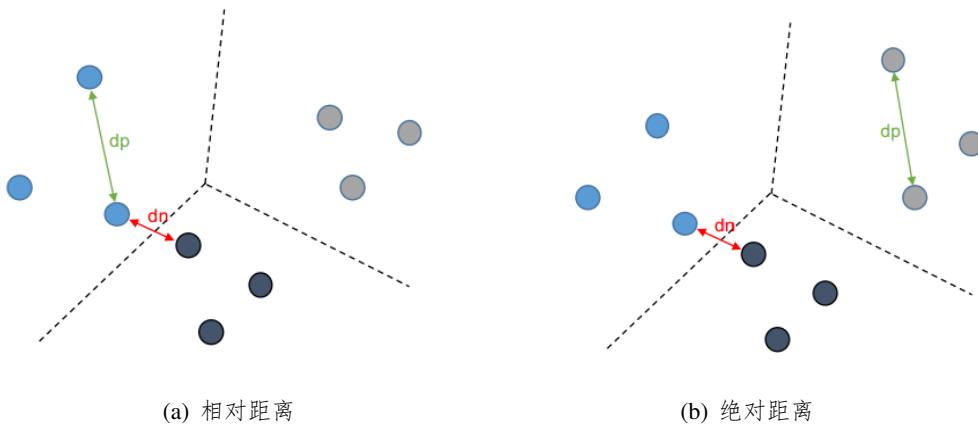


图 4-1 MSML的两种情况

为了对比MSML和传统度量学习方法的结果, 我们在Market1501、MARS、CUHK-SYSU和CUHK03公开数据集上进行了对比实验。为了减少实验数量, 我们用所有的数据训练一个模型, 并在几个数据集上分别进行测试。其中CUHK03只测评了CMC, 而剩下的数

表 4-1 MSML和其他度量学习方法的结果对比

Base model	Methods	Market1501			MARS			CUHK-SYSU			CUHK03		
		mAP	r = 1	r = 5	mAP	r = 1	r = 5	mAP	r = 1	r = 5	r=1	r=5	r = 10
ShuffleNet	Cls	38.4	64.7	83.1	43.6	61.9	78.3	76.7	80.0	90.7	54.3	74.3	80.0
	Tri	60.3	79.6	93.1	59.2	74.0	87.0	<b>88.6</b>	<b>90.2</b>	<b>96.6</b>	78.7	94.8	97.9
	Quad	57.9	77.9	91.9	58.1	73.3	86.8	87.2	89.2	96.5	78.6	94.5	97.3
	TriHard	65.2	82.3	93.6	69.7	81.0	91.7	84.6	86.5	95.1	81.3	95.4	97.8
	MSML	<b>69.7</b>	<b>85.3</b>	<b>94.4</b>	<b>72.0</b>	<b>82.6</b>	<b>93.5</b>	87.9	90.0	96.3	<b>85.7</b>	<b>97.2</b>	<b>98.8</b>
Resnet50	Cls	41.3	65.8	83.5	43.3	59.3	75.2	70.7	75.0	88.1	51.2	72.6	81.8
	Tri	54.8	75.9	89.6	62.1	76.1	89.6	82.6	85.1	94.1	73.0	92.0	96.0
	Quad	61.1	80.0	91.8	62.1	74.9	88.9	85.6	87.8	95.7	79.1	95.3	97.9
	TriHard	68.0	83.8	93.1	71.3	82.5	92.1	82.4	85.1	94.7	79.5	95.0	98.0
	MSML	<b>69.6</b>	<b>85.2</b>	<b>93.7</b>	<b>72.0</b>	<b>83.0</b>	<b>92.6</b>	<b>87.2</b>	<b>89.3</b>	<b>96.4</b>	<b>84.0</b>	<b>96.7</b>	<b>98.2</b>
Inception-v2	Cls	40.7	66.3	84.1	45.0	62.6	77.9	74.2	78.2	89.7	50.5	68.8	77.4
	Tri	57.9	78.3	91.8	55.5	70.7	85.2	87.7	89.7	96.6	76.9	93.7	97.2
	Quad	66.2	83.9	93.6	65.3	77.8	89.9	88.3	90.2	96.6	81.9	96.1	98.3
	TriHard	73.2	86.8	<b>95.4</b>	74.3	84.1	93.5	83.5	86.1	95.2	85.5	97.2	98.7
	MSML	<b>73.4</b>	<b>87.7</b>	95.2	<b>74.6</b>	<b>84.2</b>	<b>95.1</b>	<b>88.4</b>	<b>90.4</b>	<b>96.8</b>	<b>86.3</b>	<b>97.5</b>	<b>98.7</b>
Resnet50-X	Cls	46.5	70.8	87.0	48.0	63.8	80.2	74.2	78.2	89.7	57.2	77.7	85.6
	Tri	69.2	86.2	94.7	68.2	79.5	91.7	<b>89.6</b>	<b>91.4</b>	97.0	82.0	96.3	98.4
	Quad	64.8	83.3	93.8	63.6	77.7	89.4	87.3	89.6	96.2	80.7	94.9	97.9
	TriHard	71.6	86.9	94.7	69.9	82.5	92.4	86.4	88.8	96.3	82.8	96.1	98.1
	MSML	<b>76.7</b>	<b>88.9</b>	<b>95.6</b>	<b>72.0</b>	<b>83.4</b>	<b>93.3</b>	<b>89.6</b>	<b>90.9</b>	<b>97.4</b>	<b>87.5</b>	<b>97.7</b>	<b>98.9</b>

据集同时测评了CMC和mAP。为了证明算法有效性，我们利用了不同的base model多次进行实验，包括Resnet50<sup>[32]</sup>、ShuffleNet<sup>[33]</sup>、Inception-v2<sup>[34]</sup>、Resnet50-Xception等主流网络。Resnet50-X是指用Xception单元<sup>[35]</sup>替代了Resnet50中所有的 $3 \times 3$ 卷积层，而一个Xception单元包括一个 $3 \times 3$ 的深度分离卷积层(Depthwise separable/Channel-wise convolutional layer)和一个 $1 \times 1$ 的卷积层。实验结果如表4-1所示，我们结合了度量学习损失和分类损失。Cls代表分类损失，Tri代表三元组损失，Quad代表四元组损失，TriHard代表TriHard损失。黑色粗体标注了最好结果，可以看出绝大多数的黑色粗体都出现在MSML的实验中。当然从实验结果也可以看出，不同的度量学习方法可能适用于不同的数据集，例如三元组损失在CUHK-SYSU上表现很好。具体实验结果可在表中查阅。

为了进一步分析MSML考虑正负样本对绝对距离带来的性能优势，我们挑选几组正负样本对并计算了它们之间的距离。最后的结果显示在图4-2中，其中蓝色的框表示正样本对，红色的框表示负样本对。框下面的黑色数字表示两幅图片在特征空间中欧式距离。如图4.2(a)，TriHard损失由于不考虑正负样本对之间的绝对距离，所以理论上存在正样本对

的距离大于负样本对的情况，实际的结果也验证了这一点。而MSML考虑了绝对距离，并且MSML的目的是为了推开正样本对和负样本对的边界，如图4.2(b)所示，正样本对和负样本对在特征空间拥有非常清晰的分界线。而MSML这种分界面清晰的特性对于一些应用是非常重要的，例如跨摄像头的多目标跟踪问题等。

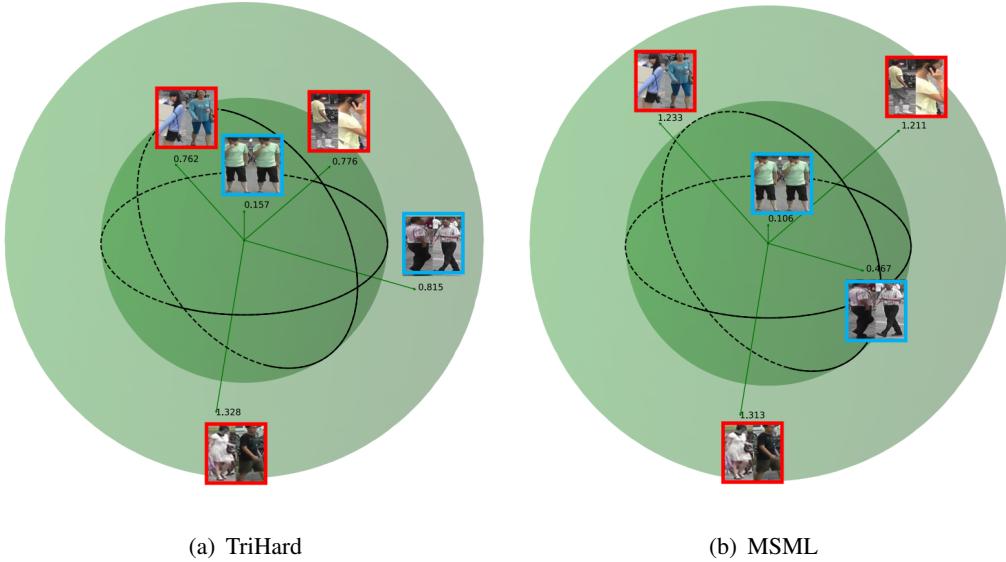


图 4-2 TriHard损失和MSML正负样本对距离分布示意图

#### 4.1.2 最短路径距离

最短路径距离(Shortest path distance, SP distance)是一种适用于自动对齐模型(Auto-alignment model, AAM)的距离度量方法。

在大多数应用中，这个距离度量选择最简单的欧式距离，但是欧式距离不考虑局部空间信息。如果只考虑全局信息，姿态、角度等变化会严重影响识别准确度。为了弥补欧式距离忽略局部空间信息的缺点，很多方法选择手动提取局部特征。基于局部特征的方法已经在前面章节介绍过了，所以这里不再赘述。在笔者所知的范围内，目前所有的局部特征对齐方法都需要一个额外的骨架关键点或者姿态估计的模型。而训练一个可以达到实用程度的模型需要收集足够多的训练数据，这个代价是非常大的。

为了解决以上问题，本文提出基于SP距离的自动对齐模型(Auto-Alignment Model, AAM)在不需要额外信息的情况下自动对齐局部特征。对于每一张图片我们使用CNN来提取最后一层的特征图(Feature map)，传统方法通常使用全局平均池化(Global average pooling, GAP)来得到全局特征。使用GAP就使得最后得到的特征失去了全部的空间信息，为此我们选择水平平均池化(Horizontal average pooling, HAP)。HAP先将特征图在垂直方向

分成相等的若干份，然后在每一行上取平均值来作为当前切片的特征值。经过HAP，我们可以得到一个 $H \times C$ 的特征，其中 $H$ 表示特征图被分割成 $H$ 均分， $C$ 表示特征图的通道数。之所以选择垂直方向的切分是因为这更符合我们对人体认知的感官直觉。据我们所知，人体结构是非常固定的，从上到下分别是头、胸脯、腰、大腿、小腿等等。在监控图片中，通常不存在水平翻转的图片。也就是说，如果按照从上往下看的顺序头部是最先出现的部位。在真实的场景下，因为遮挡和相机视角的变化，其中一张图片的头部也许不能对齐另外一张图片的头部。此外，模型提取的行人边框也有可能不准确。所以，我们提出利用最短路径理论来自动对齐两张图片中相同的行人部位。

给定两张图片的局部特征 $F = \{f_1, \dots, f_H\}$  and  $G = \{g_1, \dots, g_H\}$ ，首先我们计算每个元素欧式距离，然后用以下公式归一化到 $[0, 1]$ :

$$d_{i,j} = \frac{e^{\|f_i - g_j\|_2} - 1}{e^{\|f_i - g_j\|_2} + 1} \quad i, j \in [1, 2, 3, \dots, H] \quad (4-6)$$

其中 $d_{i,j}$ 表示图片1第*i*部分和图片2第*j*部分的归一化后的距离，之后我们便可以得到一个 $H \times H$ 的距离矩阵 $D$ 。考虑到人体结构是一个连续不变结构，即各部分的相关顺序是不变的，所以我们从上到下比较各部分的相似度。两张图片的SP距离可以定义为矩阵从 $(1, 1)$ 到 $(H, H)$ 的最短路径，这个可以通过动态规划来求解：

$$S_{i,j} = \begin{cases} d_{i,j} & i = 1, j = 1 \\ S_{i-1,j} + d_{i,j} & i \neq 1, j = 1 \\ S_{i,j-1} + d_{i,j} & i = 1, j \neq 1 \\ \min(S_{i-1,j}, S_{i,j-1}) + d_{i,j} & i \neq 1, j \neq 1 \end{cases} \quad (4-7)$$

其中 $S_{i,j}$ 表示当前从 $(1, 1)$ 到 $(i, j)$ 的最短路径，而 $S_{H,H}$ 是两张图片的最终最短路径距离。由于并不存在复杂的计算子，所以该方法的反向传播可以通过大部分框架都自带的自动求导实现。

为了更加直观的解释最短路径距离，我们给出了一个示例。如图4-3所示，其中黑色实线连接了左右两幅图像中最相似的两部分。在本论文中我们采用残差网络(Resnet)<sup>[32]</sup>作为基础模型(Base model)，所以最后的feature map的尺寸为 $7 \times 7$ ，因此图片被分割成了7部分。图片中的数字表示区域ID，右边的黑色箭头是最后求解出来的最短路径。首先，我们连接 $f_1$ 和 $g_1$ ，因为它们是路径的开端。之后我们比较 $d_{1,2}$ 和 $d_{2,1}$ 发现 $d_{2,1} > d_{1,2}$ ，所以我们认为图片A的第1区域和图片B的第2区域更加相似。所以我们连接图片A的第1区域和图片B的第2区域，在右边的图片反映为从 $(1, 1)$ 走到 $(1, 2)$ 。之后我们比较 $d_{2,2}$ 和 $d_{1,3}$ ，因为 $d_{2,2} > d_{1,3}$ ，

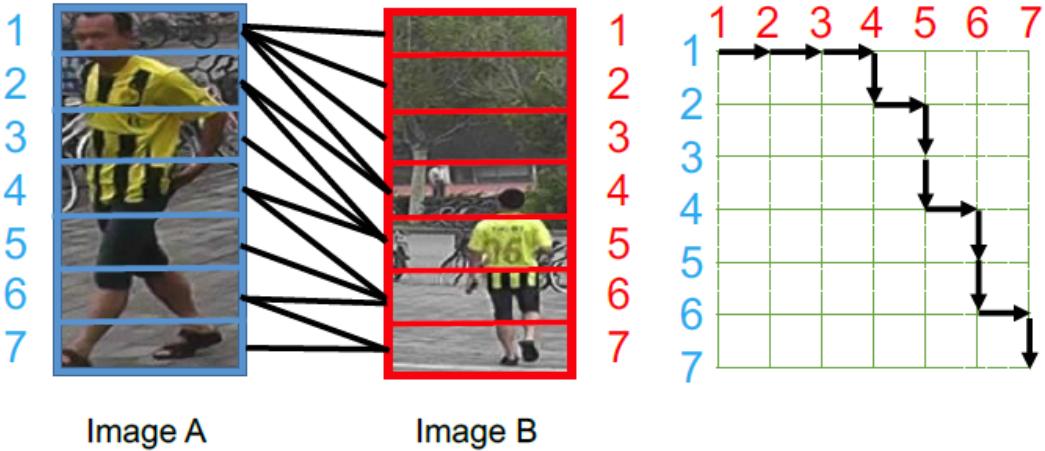


图 4-3 基于SP距离的AAM模型算法示例

所以连接图片A的第1区域和图片B的第3区域，在右边的图片反映为从(1, 2)走到(1, 3)。按照这种规律寻找下去，最终的最短路径如图4-3右半所示。

我们的SP距离可以应用于各种度量学习损失，在本论文中我们使用前文介绍的TriHard损失<sup>[19]</sup>。对于每一个训练batch包含 $N = P \times K$ 张图片，即P个ID的行人，每个行人随机挑选K张不同的图片。给定 $I_1$ 和 $I_2$ 两张图片，我们定义 $S_{local}(I_1, I_2)$ 为它们的SP距离，定义 $D_{global}(I_1, I_2)$ 为它们的全局L2距离。如图4-4，我们结合了L2 TriHard损失和SP TriHard损失，最终损失函数 $L_t$ 为：

$$\begin{aligned}
 L_t &= \frac{1}{N} \sum_{a \in batch} \left[ \left( S_{local}(a, p) - S_{local}(a, n) + \alpha \right)_+ + \left( D_{global}(a, p) - D_{global}(a, n) + \beta \right)_+ \right] \\
 p &= \arg \max_{p \in A} D_{global}(a, p) \\
 n &= \arg \min_{n \in B} D_{global}(a, n)
 \end{aligned} \tag{4-8}$$

值得说明的是，我们选择用L2距离来进行难样本采样(Hard sample mining, HSM)，HSM的结果用于同时计算L2 TriHard损失和SP TriHard损失。最终采用的网络结构示意图如图4-4所示，网络每个训练batch会输入N张图片。每张图片经过CNN的几个卷积层得到feature maps，feature maps之后分为两个分支。其中一个分支和传统的方法一样经过GAP得到全局L2特征，并计算得到一个 $N \times N$ 的L2距离矩阵，该矩阵用于进行HSM。另外一个分支用HAP得到局部特征并采用一个卷积层CONV降低特征的通道数，最终得到的feature maps用于计算SP距离矩阵。最终的损失函数融合了两个分支的损失，共享HSM结果是为了保证两个分支计算损失时用的是相同的采样图片。之所以选择L2距离来进行HSM主要基于两点考虑。一个是SP距离计算比L2距离计算耗时，在实现上可

以只计算HSM样本的SP距离（虽然本文实现上并非如此）。另一个是我们发现利用SP进行HSM并没有显著地带来性能提升。

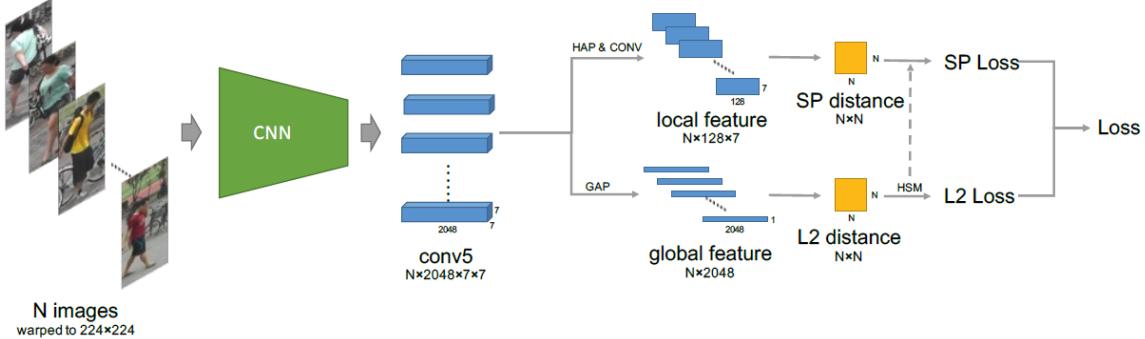


图 4-4 基于TriHard损失的AAM网络结构示意图

在本论文中，我们采用Resnet50和Resnet50-Xception(Resnet50-X)分别进行了对别实验。对于同一个base model，我们采用传统的L2距离和本文提出的结合L2和SP距离的AAM模型进行了对比。我们采用了Market1501、MARS、CUHK-SYSU和CUHK03四个公开数据集来训练一个模型，并分别在这四个数据集上进行了测试。除了CUHK03数据集只计算了CMC以外，另外三个数据集都评测了CMC和mAP。结果表明，AAM模型能够显著地提高行人重识别的准确度，Resnet50和Resnet50-X都得到了类似的结果，具体数值可以看表4-2。

表 4-2 SP距离和L2距离度量结果对比

Base model	Methods	Market1501			MARS			CUHK-SYSU			CUHK03		
		mAP	r = 1	r = 5	mAP	r = 1	r = 5	mAP	r = 1	r = 5	r=1	r=5	r = 10
Resnet50	TriHard+L2	71.2	86.5	94.2	72.1	83.2	92.5	86.0	88.4	95.7	82.7	95.7	98.1
	TriHard+SP	<b>79.0</b>	<b>91.3</b>	<b>95.8</b>	<b>78.8</b>	<b>86.7</b>	<b>94.7</b>	<b>91.0</b>	<b>93.1</b>	<b>97.4</b>	<b>88.8</b>	<b>97.4</b>	<b>98.6</b>
Resnet50-X	TriHard+L2	71.6	86.9	94.7	69.9	82.5	92.4	86.4	88.8	96.3	82.8	96.1	98.1
	TriHard+SP	<b>79.4</b>	<b>91.0</b>	<b>96.3</b>	<b>78.3</b>	<b>86.1</b>	<b>95.0</b>	<b>91.5</b>	<b>93.4</b>	<b>97.6</b>	<b>88.2</b>	<b>97.0</b>	<b>98.5</b>

### 4.1.3 基于度量学习的互学习方法

本小节介绍了一种基于度量学习的互学习方法(Mutual learning)。深度互学习(Deep mutual learning, DML)是论文<sup>[36]</sup>首次提出，是指利用两个或者多个网络同时训练互相学习，来提升单个网络的性能。该论文利用KL散度(Kullback-Leibler divergence)衡量两个分类器的性能差异。如图4-5,假设 $p_1$ 和 $p_2$ 是两个分类器的预测，定义 $p_1$ 到 $p_2$ 的KL距离为：

$$D_{KL}(p_2||p_1) = \sum_{i=1}^N \sum_{m=1}^M p_2^m(x_i) \log \frac{p_2^m(x_i)}{p_1^m(x_i)} \quad (4-9)$$

DML目标是为了使两个分类器的预测性能足够接近，即KL距离足够小，于是在两个分类器的损失函数上加上各自的KL距离。最终两个分类器的损失函数写作：

$$\begin{aligned} L_{\theta_1} &= L_{C_1} + D_{KL}(p_2 || p_1) \\ L_{\theta_2} &= L_{C_2} + D_{KL}(p_1 || p_2) \end{aligned} \quad (4-10)$$

其中 $L_{C_1}$ 和 $L_{C_2}$ 分别是两个网络的分类损失。

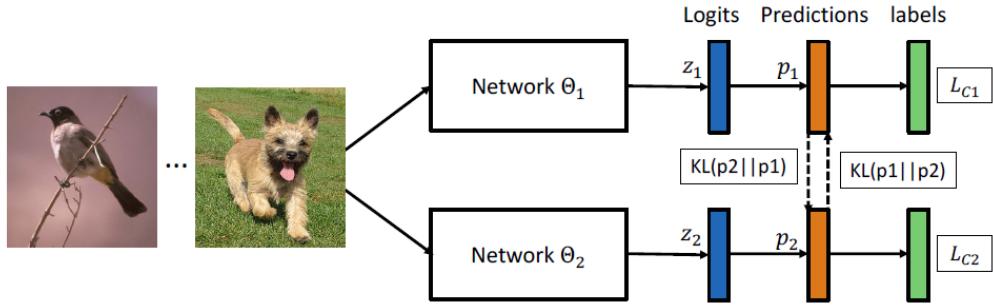


图 4-5 基于分类损失的深度互学习结构

DML是一个通用的基于分类损失的互学习模型。在行人ReID领域，DarkRank<sup>[37]</sup>首次采样这种思想。DarkRank的核心思想是，首先训练一个性能非常好的大网络，这个网络成为Teacher网络。之后用这个Teacher网络和一个小网络一起进行互学习，这个小网络称为Student网络。通过这种互学习方法，Student网络能够从Teacher网络身上学习到知识，最终达到和Teacher网络差不多的性能。于是，小网络Student网络可以达到它自学无法达到的性能。但是由于KL散度只适合衡量两个分类器的性能差异，所以不适合应用到度量学习相关的方法中。然而在行人重识别以及人脸识别等目前主流应用中，度量学习是比表征学习更加有效的方法。因此，我们提出一种基于度量学习的互学习方法(Mutual learning based on metric learning)。

首先，给定一个包含 $N$ 张图片的batch，每个网络都提取它们的特征，之后我们可以计算任意两张图片之间的距离并得到一个 $N \times N$ 的batch距离矩阵(batch distance matrix, BDM)。假设我们有网络 $\theta_1$ 和 $\theta_2$ ，它们的BDM分别是 $M^{\theta_1}$ 和 $M^{\theta_2}$ ，则损失函数可以简单地定义为：

$$L_{M_1} = \frac{1}{N^2} \sum_i^N \sum_j^N (M_{ij}^{\theta_1} - M_{ij}^{\theta_2})^2 \quad (4-11)$$

之后我们可以计算 $L_{M_1}$ 关于 $M_{ij}^{\theta_1}$ 的一阶偏导：

$$\frac{\partial L_{M_1}}{\partial M_{ij}^{\theta_1}} = \frac{2}{N^2} (M_{ij}^{\theta_1} - M_{ij}^{\theta_2}) \quad (4-12)$$

考虑到一些优化算法用到了二阶偏导，于是我们计算它的二阶偏导：

$$\frac{\partial^2 L_{M_1}}{\partial M_{ij}^{\theta_1} \partial M_{ij}^{\theta_2}} = -\frac{2}{N^2} \quad (4-13)$$

从中可以看出，在二阶偏导上网络 $\theta_1$ 和网络 $\theta_2$ 是不正交的。收到论文<sup>[36]</sup>，我们希望两个网络更新参数的时候尽可能独立的。于是我们将公式4-11简单地扩展为：

$$L_{M_2} = \frac{1}{N^2} \sum_i^N \sum_j^N \left( [ZG(M_{ij}^{\theta_1}) - M_{ij}^{\theta_2}]^2 + [M_{ij}^{\theta_1} - ZG(M_{ij}^{\theta_2})]^2 \right) \quad (4-14)$$

其中 $ZG(\cdot)$ 代表零梯度函数(Zero gradient function)。当计算梯度时，零梯度函数把变量当常数对待。类似的我们计算一阶偏导和二阶偏导：

$$\frac{\partial L_{M_2}}{\partial M_{ij}^{\theta_1}} = \frac{2}{N^2} (M_{ij}^{\theta_1} - ZG(M_{ij}^{\theta_2})) = \frac{\partial L_{M_1}}{\partial M_{ij}^{\theta_1}} \quad (4-15)$$

$$\frac{\partial^2 L_{M_2}}{\partial M_{ij}^{\theta_1} \partial M_{ij}^{\theta_2}} = 0 \quad (4-16)$$

一阶导数依然保持不变，但是二阶偏导等于0，也就是说在二阶偏导上两个网络是完全正交的。当我们优化 $L_{M_2}$ 时，子网络们可以互相从对方学习知识。我们让两个网络独立地从对方学习知识比他们“一起作弊”要好。DarkRank是让一个Student网络从Teacher网络里学习知识，也就是说Student网络的性能上界就是Teacher网络在，这也要求Teacher网络需要有很好的性能。和DarkRank不同，我们的方法是让几个网络互相学习，并没有限制网络能够达到的性能上界，也不需要一个性能比较好的网络来带领其他网络。最终，我们的互学习方法结构如图4-3所示，整个损失函数包括分类损失、基于SP的度量损失 $L_t$ 、基于分类的互学习KL损失和本文提出的基于度量学习的互学习损失 $L_{M_2}$ 。

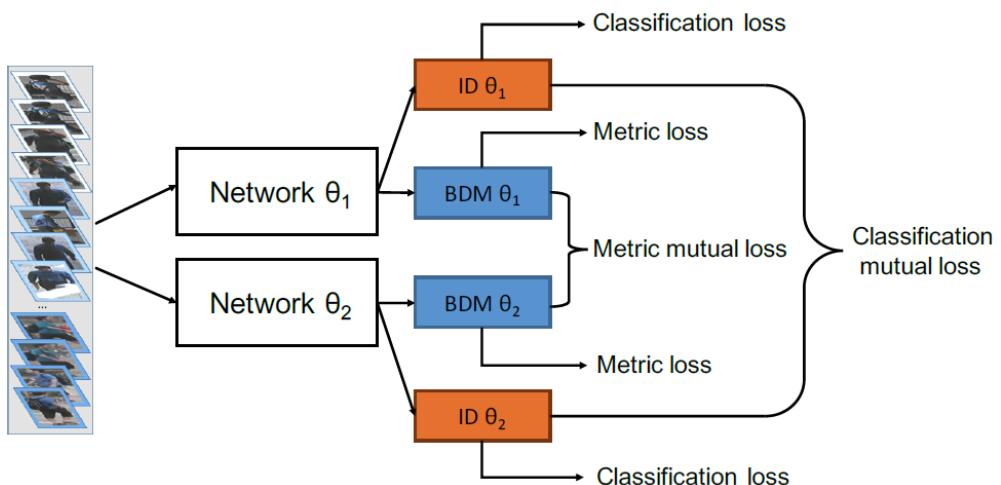


图 4-6 基于度量学习的互学习方法结构示意图

表 4-3 互学习实验结果对比

Loss	Base model	Market1501			MARS			CUHK-SYSU			CUHK03		
		mAP	r = 1	r=5	mAP	r = 1	r=5	mAP	r = 1	r=5	r = 1	r = 5	r = 10
L2+/ Resnet50	Resnet50	71.2	86.5	94.2	72.1	83.2	92.5	86.0	88.4	95.7	82.7	95.7	98.1
	Resnet50-X	71.6	86.9	94.7	69.9	82.5	92.4	86.4	88.8	96.3	82.8	96.1	98.1
L2+KL Resnet50	Resnet50	77.3	90.5	96.5	74.2	84.9	94.8	89.6	91.7	96.8	86.5	96.7	98.4
	Resnet50-X	77.1	90.6	96.4	74.4	84.9	93.7	89.6	92.1	96.8	86.8	96.7	98.2
L2+Ours Resnet50	Resnet50	77.6	90.9	96.6	75.0	85.1	94.8	91.3	93.4	98.5	87.5	97.5	98.8
	Resnet50-X	78.3	90.9	96.6	75.8	85.7	94.9	91.7	93.7	97.7	88.2	97.6	98.8
SP+/ Resnet50	Resnet50	79.0	91.3	95.8	78.8	86.7	94.7	91.0	93.1	97.4	88.8	97.4	98.6
	Resnet50-X	79.4	91.0	96.3	78.3	86.1	95.0	91.5	93.4	97.6	88.2	97.0	98.5
SP+KL Resnet50	Resnet50	79.3	91.1	97.1	75.3	84.1	93.6	92.1	94.1	97.9	90.6	98.4	99.2
	Resnet50-X	79.1	91.0	96.3	76.3	85.5	94.8	91.5	93.3	97.5	88.4	97.8	99.0
SP+Ours Resnet50	Resnet50	82.2	92.4	97.1	79.1	86.8	95.2	93.7	95.3	98.5	91.9	98.7	99.4
	Resnet50-X	82.3	92.6	97.2	78.5	87.3	95.3	93.2	94.6	98.4	91.1	98.6	99.3
	Ensemble	83.9	93.3	97.3	80.2	87.7	95.6	93.7	95.2	98.5	92.5	98.7	99.4

在本论文中，我们使用Market1501、MARS、CUHK-SYSU和CUHK03公开数据集进行了实验，实验采取Resnet50和Resnet50-X作为互学习的两个网络。为了证明有效性，我们使用L2距离和SP距离分别进行了对比实验，最终实验结果如表4-3所示。其中字符”/”代表没有使用互学习，分别单独训练的基准实验。KL为论文<sup>[36]</sup>提出的基于分类损失的互学习方法，而ours是指本文提出的互学习方法。Ensemble是指我们连接了两个模型提取的特征来提升性能。对于L2和SP距离，实验表明我们的方法比只用KL损失的互学习方法和不用互学习方法要取得更好的结果。并且实验在另一个侧面进一步证明了SP距离比L2距离能够取得更好的结果。

#### 4.1.4 行人重识别的人类准确度评估

为了测试我们的行人重识别方法的性能，我们设计了一个人类准确度评估系统(Human performance evaluation system)来测评人类在行人重识别问题上的表现。该系统使用了前文介绍的Market1501、CUHK03和MARS数据集。

首先，我们先用我们训练好的模型提取所有数据集测试集中的图像特征，之后计算query集中每一张图片和gallery集中每一张图片的欧拉距离。对于query中的每一张probe图片，我们挑选一张距离最近（最像/最简单）的正样本和九张距离最近（最像/最难的）的负样本。为了方便测试，我们开发了一个评估系统，系统截图如图4-7所示。待测者要从这10张图片中选择出哪张和probe图片是相同的ID。

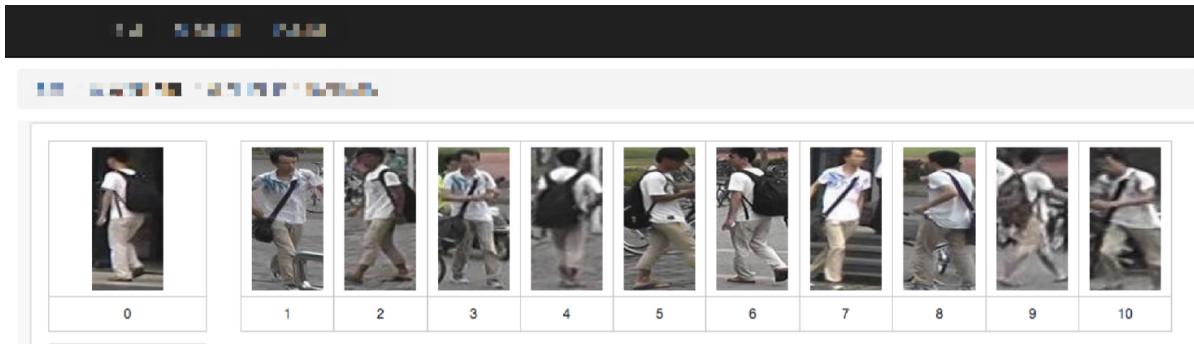


图 4-7 行人重识别的人类准确度评估界面

总共有10位志愿者参加了我们的测试，其中包括我们课题的研究人员、专业的标注全职员工和一般的普通市民。根据我们系统的设计原理，我们只能统计CMC曲而不能计算mAP准确度。最终为了我们统计10位测试者的在Market1501、CUHK03和MARS三个数据集上rank-1准确度，并且选择了其中成绩最好的结果作为人类准确度(Human performance)。结果如表所示4-4，CUHK03因为gallery集数据量比较少，所以最后结果最高达到了95.7%的rank-1准确度。在Market1501和MARS数据集上，人类分别取得了91.8%和90.2%的rank-1准确度。

表 4-4 人类准确度评估结果.

	Market1501	CUHK03	MARS
Rank-1	91.8	95.7	90.2

#### 4.1.5 与现有方法结果对比

在本小节我们将会对比我们的方法与一些现有方法的结果。此外，我们还进行了一场行人重识别的人机大战，对人类准确度和计算机的准确度。结果表明，我们的方法在所使用的Market1501、MARS、CUHK-SYSU以及CUHK03这四个数据集上，都大大超过了现有方法的准确度，并且首次超越了人类准确度。

表 4-5 Caption for total table

(a) Caption for table 1	(b) Caption for table 2
1 2 3	a b c

## 4.2 成果作品

本文作者已经撰写学术论文三篇和发明专利两篇。其中学术论文有一篇一作期刊论文已经录用，一篇一作论文在投计算机视觉顶会CVPR2018，一篇二作论文arxiv已经挂出待投。发明专利其中一篇处于审核状态，一篇处于编修状态。

- (1) H Luo, Z Luo, C Xu, W Jiang, et al. Optical plasma boundary reconstruction based on least square for EAST Tokamak[J]. *Frontiers of Information Technology & Electronic Engineering*, In Press.
- (2) H Luo, X Fan, C Zhang, et al. AAM: A Deep Learning Method for Person Re-Identification Outperforming Human Performance. Contribute to CVPR, 2018.
- (3) Q. Xiao, H. Luo, and C. Zhang. Margin Sample Mining Loss: A Deep Learning Based Method for Person Re-identification. *arXiv preprint arXiv:1710.00478*, 2017.
- (4) 罗浩, 张弛. 一种联合五元组和分类损失的行人重识别方法。
- (5) 罗浩, 张弛. 一种基于边界样本挖掘的行人重识别方法。

## 4.3 研究现状

## 参考文献

- [1] Liang Zheng, Liyue Shen, Lu Tian, Shengjin Wang, Jingdong Wang, Qi Tian. Scalable person re-identification: A benchmark[C]//Computer Vision, IEEE International Conference. 2015.
- [2] Springer. MARS: A Video Benchmark for Large-Scale Person Re-identification[J], 2016, 2016.
- [3] Wei Li, Rui Zhao, Tong Xiao, Xiaogang Wang. Deepreid: Deep filter pairing neural network for person re-identification[J]. 2014:152–159.
- [4] Tong Xiao, Shuang Li, Bochao Wang, Liang Lin, Xiaogang Wang. End-to-end deep learning for person search[J]. arXiv preprint arXiv:1604.01850, 2016.
- [5] Ergys Ristani, Francesco Solera, Roger Zou, Rita Cucchiara, Carlo Tomasi. Performance measures and a data set for multi-target, multi-camera tracking[C]//European Conference on Computer Vision workshop on Benchmarking Multi-Target Tracking. 2016.
- [6] Doug Gray, Shane Brennan, Hai Tao. Evaluating appearance models for recognition, reacquisition, and tracking[J]. 2007.
- [7] Martin Hirzer, Csaba Beleznai, Peter M. Roth, Horst Bischof. Person re-identification by descriptive and discriminative classification[C]//Scandinavian Conference on Image Analysis. 2011:91–102.
- [8] Mengyue Geng, Yaowei Wang, Tao Xiang, Yonghong Tian. Deep transfer learning for person re-identification[J]. arXiv preprint arXiv:1611.05244, 2016.
- [9] Yutian Lin, Liang Zheng, Zhedong Zheng, Yu Wu, Yi Yang. Improving person re-identification by attribute and identity learning[J]. arXiv preprint arXiv:1703.07220, 2017.
- [10] Liang Zheng, Yi Yang, Alexander G Hauptmann. Person re-identification: Past, present and future[J]. arXiv preprint arXiv:1610.02984, 2016.
- [11] Tetsu Matsukawa, Einoshin Suzuki. Person re-identification using cnn features learned from combination of attributes[C]//Pattern Recognition (ICPR), 2016 23rd International Conference on. IEEE, 2016:2428–2433.
- [12] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks[C]//International Conference on Neural Information Processing Systems. 2012:1097–1105.
- [13] Rahul Rama Varior, Mrinal Haloi, Gang Wang. Gated siamese convolutional neural network architecture for human re-identification[C]//European Conference on Computer Vision. Springer, 2016:791–808.
- [14] Florian Schroff, Dmitry Kalenichenko, James Philbin. Facenet: A unified embedding for face recogni-

- tion and clustering[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015:815–823.
- [15] Hao Liu, Jiashi Feng, Meibin Qi, Jianguo Jiang, Shuicheng Yan. End-to-end comparative attention networks for person re-identification[J]. IEEE Transactions on Image Processing, 2017.
- [16] De Cheng, Yihong Gong, Sanping Zhou, Jinjun Wang, Nanning Zheng. Person re-identification by multi-channel parts-based cnn with improved triplet loss function[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016:1335–1344.
- [17] Weihua Chen, Xiaotang Chen, Jianguo Zhang, Kaiqi Huang. Beyond triplet loss: a deep quadruplet network for person re-identification[J]. arXiv preprint arXiv:1704.01719, 2017.
- [18] Hongye Liu, Yonghong Tian, Yaowei Wang, Lu Pang, Tiejun Huang. Deep relative distance learning: Tell the difference between similar vehicles[C]//Computer Vision and Pattern Recognition. 2016:2167–2175.
- [19] Alexander Hermans, Lucas Beyer, Bastian Leibe. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.
- [20] Qiqi Xiao, Kelei Cao, Haonan Chen, Fangyue Peng, Chi Zhang. Cross domain knowledge transfer for person re-identification[J]. arXiv preprint arXiv:1611.06026, 2016.
- [21] Rahul Rama Varior, Bing Shuai, Jiwen Lu, Dong Xu, Gang Wang. A siamese long short-term memory architecture for human re-identification[C]//European Conference on Computer Vision. Springer, 2016:135–153.
- [22] Liang Zheng, Yujia Huang, Huchuan Lu, Yi Yang. Pose invariant embedding for deep person re-identification[J]. arXiv preprint arXiv:1701.07732, 2017.
- [23] Haiyu Zhao, Maoqing Tian, Shuyang Sun, Jing Shao, Junjie Yan, Shuai Yi, Xiaogang Wang, Xiaou Tang. Spindle net: Person re-identification with human body region guided feature decomposition and fusion[C]. CVPR, 2017.
- [24] Longhui Wei, Shiliang Zhang, Hantao Yao, Wen Gao, Qi Tian. Glad: Global-local-alignment descriptor for pedestrian retrieval[J]. arXiv preprint arXiv:1709.04329, 2017.
- [25] Taiqing Wang, Shaogang Gong, Xiatian Zhu, Shengjin Wang. Person re-identification by discriminative selection in video ranking[J]. IEEE transactions on pattern analysis and machine intelligence, 2016. 38(12):2501–2514.
- [26] Dongyu Zhang, Wenxi Wu, Hui Cheng, Ruimao Zhang, Zhenjiang Dong, Zhaoquan Cai. Image-to-video person re-identification with temporally memorized similarity learning[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017.
- [27] Jinjie You, Ancong Wu, Xiang Li, Wei-Shi Zheng. Top-push video-based person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016:1345–1353.

- [28] Xiaolong Ma, Xiatian Zhu, Shaogang Gong, Xudong Xie, Jianming Hu, Kin-Man Lam, Yisheng Zhong. Person re-identification by unsupervised video matching[J]. Pattern Recognition, 2017. 65:197–210.
- [29] Niall McLaughlin, Jesus Martinez del Rincon, Paul Miller. Recurrent convolutional network for video-based person re-identification[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016:1325–1334.
- [30] Rui Zhao, Wanli Oyang, Xiaogang Wang. Person re-identification by saliency learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2017. 39(2):356–370.
- [31] Hao Liu, Zequn Jie, Karlekar Jayashree, Meibin Qi, Jianguo Jiang, Shuicheng Yan, Jiashi Feng. Video-based person re-identification with accumulative motion context[J]. arXiv preprint arXiv:1701.00193, 2017.
- [32] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:770–778.
- [33] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices[J]. arXiv preprint arXiv:1707.01083, 2017.
- [34] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, Andrew Rabinovich. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015:1–9.
- [35] François Chollet. Xception: Deep learning with depthwise separable convolutions[J]. arXiv preprint arXiv:1610.02357, 2016.
- [36] Ying Zhang, Tao Xiang, Timothy M Hospedales, Huchuan Lu. Deep mutual learning[J]. arXiv preprint arXiv:1706.00384, 2017.
- [37] Yuntao Chen, Naiyan Wang, Zhaoxiang Zhang. Darkrank: Accelerating deep metric learning via cross sample similarities transfer[J]. arXiv preprint arXiv:1707.01220, 2017.